Curso: Análise e Desenvolvimento de sistemas

Disciplina: Inteligência Artificial

Processamento Digital de Imagens Aéreas e Análise Topográfica Matricial via Python e WebODM

1. Identificação da equipe

Grupo composto pelos integrantes: Gustavo Barros Martins, Hugo Alexandre Carvalho Coelho Coutinho, Jeferson Machado dos Santos e Maicon de Sousa Pontes.

1.5 Link do repositório BIG DATA

https://github.com/HugoAlexandreCarvalho/Geo_Map

2. Apresentação da equipe ou cliente atendido

O cliente atendido é um engenheiro autônomo que prefere não ser identificado em um primeiro momento.

3. Descrição do problema identificado

Um dos grandes problemas enfrentados pelo profissional é o grande investimento de tempo em algumas atividades que poderiam facilmente ter o seu processo automatizado, como elas:

Necessidade constante de responder dúvidas superficiais de novos clientes e agendar visitas (interrompendo o trabalho técnico e gerando um atraso no processo atual).

Mapeamento manual de terrenos e análise de dados de elevação também consomem bastante o tempo do engenheiro, além de estarem sujeitos a erros humanos de interpretação.

4. Justificativa da solução proposta

Para uma solução do problema enfrentado com atendimento dos clientes e possíveis clientes, será implementado, no sistema que o grupo está desenvolvendo, um agente virtual baseado em LLMs para realizar uma triagem inicial. Capturar as necessidades dos clientes e extrair informações cruciais como (metragem, localização e tipo de obra). Já para processo de mapeamento e processamento de dados topográficos, algoritmos podem processar matrizes de dados de telemetria coletadas por drones para gerar modelos digitais do terreno. A IA pode ser programada para varrer automaticamente essas matrizes de altitude, identificando padrões, zonas de risco de alagamento ou os pontos mais seguros e nivelados para fundações e pousos, reduzindo o tempo de análise de dias para minutos.

5. Pesquisa e fundamentação do problema

Embora o uso de drones tenha agilizado as coletas em campo, o processamento do volume massivo das matrizes de elevação tornou-se um novo gargalo, visto que analisar milhares de coordenadas manualmente para encontrar áreas planas é exaustivo e frequentemente trava os softwares CAD tradicionais. Para superar essa barreira e extrair inteligência dos dados em tempo hábil, a automatização do processo através de scripts baseados em vetores e matrizes apresenta-se como a solução ideal. Essa abordagem elimina falhas de interpretação visual e reduz o tempo de análise de dias para minutos, permitindo a entrega de mapeamentos e projetos estruturais mais eficientes e amparados em rigorosas avaliações matemáticas.

6. Lean Canvas



7. Funcionalidades Essenciais

Ingestão e Tratamento de Dados Brutos: Módulo responsável pelo recebimento, leitura e parsing de arquivos de telemetria e imagens georreferenciadas. O componente realiza a conversão dos dados de altitude em matrizes numéricas manipuláveis para processamento matemático posterior.

Motor de Análise Matricial (Core): Algoritmo de varredura espacial projetado para subdividir o terreno em recortes matriciais (ex.: matrizes 4x4) e calcular os gradientes de inclinação. Esta rotina identifica automaticamente as coordenadas geográficas correspondentes a declives nulos ou próximos de zero (superfícies planas).

Módulo de Anotação e Filtragem: Funcionalidade voltada ao carregamento de máscaras de segmentação e delimitadores (bounding boxes), permitindo a exclusão automatizada de elementos indesejados (como vegetação, corpos d'água e edificações) da análise topográfica.

Exportação e Integração CAD: Sistema de geração de mapas de calor simplificados em formato de imagem e exportação dos polígonos representativos das zonas ideais para fundação em formatos vetoriais padronizados e compatíveis com softwares CAD (como .dxf).

8. Hipótese de Validação e Metodologia de Teste

8.1. Formulação da Hipótese

"A automatização da exportação de polígonos de fundação, por meio de algoritmos de análise de gradiente, reduzirá em no mínimo 50% o tempo dispendido por engenheiros civis e topógrafos no mapeamento de áreas seguras em comparação ao método de análise visual manual , mantendo o nível de precisão técnica exigido pelas normas da engenharia."

8.2. Procedimento de Teste

A validação será conduzida mediante a submissão de conjuntos de dados de telemetria oriundos de voos de drone em um terreno previamente documentado. Os resultados (outputs) gerados pelo script serão entregues a um engenheiro especialista para a realização de um estudo comparativo cego, avaliando a concordância espacial entre os polígonos gerados automaticamente e as áreas demarcadas manualmente pelo profissional.

9. Arquitetura Tecnológica e Ferramentas (Stack e IA)

A arquitetura do sistema foi desenvolvida priorizando o processamento local, a modularidade e o controle estrito sobre o fluxo de dados.

9.1. Ambiente e Infraestrutura de Desenvolvimento

Sistema Operacional: Ambiente Linux (distribuição Ubuntu), selecionado visando à máxima compatibilidade com bibliotecas open-source de fotogrametria, estabilidade de execução e eficiência na gestão de dependências.

Linguagem de Programação: Python, estruturado em scripts modulares projetados para execução via linha de comando no terminal.

Isolamento de Ambiente: Utilização de ambientes virtuais (venv) para a gestão individualizada de dependências, evitando conflitos entre o motor de cálculo numérico e as ferramentas de visão computacional.

9.2. Processamento Matemático e Algorítmico

NumPy e SciPy: Bibliotecas empregadas para a execução de operações algébricas de alto desempenho e fatiamento matricial (slicing) sobre os dados de altitude. Permitem a identificação rigorosa dos gradientes de inclinação sem demandar consumo excessivo de recursos computacionais.

9.3. Visão Computacional e Inteligência Artificial

A camada de Inteligência Artificial atua na classificação do terreno e no pré-processamento das imagens:

LabelMe: Ferramenta executada em ambiente virtual dedicado para a criação e estruturação do dataset. É utilizada no processo de anotação manual de ortomosaicos (definição de polígonos), rotulando obstáculos e vegetações a serem suprimidas.

OpenCV: Biblioteca responsável pelas rotinas de pré-processamento, filtragem e normalização das imagens aéreas obtidas pelo drone, antecedendo as etapas de análise matricial ou de treinamento de modelos.

Modelos de Segmentação Semântica: Implementação de arquiteturas de redes neurais convolucionais leves (como U-Net ou YOLO adaptadas para segmentação de instâncias). O modelo será treinado com o conjunto de anotações exportado do LabelMe, viabilizando a classificação automatizada e o isolamento do "solo nu" em relação aos elementos adjacentes do terreno.

10. Cronograma simplificado

Atividade	Ago	Set	Out	Nov
Infraestrutura	X			
Motor Matemático	X	X		
Visão e Anotação		X	X	
Exportação			X	
Validação			X	X
Deploy & Entrega				X

TED de Big Data e Ciência de Dados

1. Contextualização e problema do projeto

O projeto GeoMap teve sua proposta inicial desenvolvida no âmbito da disciplina de Inteligência Artificial, tendo como contexto a necessidade de auxiliar um engenheiro autônomo na análise de terrenos a partir de imagens aéreas obtidas por drones.

Entre os problemas identificados estava o tempo necessário para realizar manualmente a interpretação dessas imagens e identificar diferentes elementos presentes no terreno. A análise pode envolver a identificação de solo, vegetação, pedras, áreas pavimentadas, construções e outros elementos, podendo se tornar trabalhosa quando existe um grande volume de imagens.

A proposta inicial contemplava o processamento de informações topográficas, como matrizes de elevação e análise das características do terreno.

Para dar continuidade ao projeto, entretanto, foi realizada uma discussão sobre a proposta e seu desenvolvimento futuro. A partir dessa orientação, houve um novo direcionamento do escopo, passando a priorizar inicialmente a utilização de Inteligência Artificial para a segmentação semântica de imagens aéreas.

Assim, o presente TED de Big Data não representa um novo projeto, mas uma continuidade do trabalho desenvolvido anteriormente, aprofundando a etapa relacionada aos dados necessários para viabilizar essa nova direção.

2. Novo direcionamento e solução/MVP

A partir do direcionamento definido após a apresentação do projeto inicial, o foco principal passou a ser o desenvolvimento de uma solução capaz de realizar a segmentação semântica de imagens aéreas obtidas por drones.

A proposta consiste em utilizar técnicas de processamento digital de imagens e Inteligência Artificial para identificar diferentes regiões presentes em uma imagem e classificá-las de acordo com suas características.

Dessa forma, uma imagem aérea poderá ser utilizada como entrada do sistema, sendo posteriormente processada por um modelo capaz de identificar diferentes elementos presentes na cena.

Entre os elementos de interesse estão:

- Solo;
- Vegetação;
- Grama;
- Pedras;
- Cascalho;
- Árvores;
- Áreas pavimentadas;
- Construções;
- Muros;
- Cercas;
- Outros elementos presentes no terreno.

O foco inicial do MVP será, portanto, a segmentação das imagens e identificação dos elementos presentes nelas.

A análise topográfica, o processamento de matrizes de elevação, medições do terreno e possíveis integrações com ferramentas CAD permanecem como funcionalidades de expansão para etapas posteriores do projeto, caso sejam viáveis durante o desenvolvimento.

3. Necessidades de dados da solução

A mudança de direcionamento também altera as necessidades de dados do projeto. Para desenvolver uma solução capaz de realizar segmentação semântica, não são suficientes apenas imagens aéreas comuns.

É necessário possuir imagens acompanhadas de informações que indiquem quais regiões ou pixels pertencem a determinadas classes. Essas informações permitem que o modelo aprenda a relacionar os elementos presentes nas imagens com suas respectivas categorias.

Dessa forma, o conjunto de dados ideal para o projeto deve apresentar:

- Imagens aéreas obtidas por drones;
- Imagens com qualidade e resolução suficientes para identificar os elementos presentes no terreno;
- Diferentes ambientes e situações;

- Classes relacionadas aos elementos de interesse;
- Anotações ou máscaras de segmentação em nível de pixel;
- Quantidade suficiente de imagens para treinamento e avaliação;
- Dados adequados para técnicas de processamento digital de imagens e aprendizado de máquina.

Além das imagens e das respectivas anotações, também são relevantes características como resolução, formato dos arquivos, quantidade de registros, volume total dos dados e condições de utilização.

Essa necessidade de dados é justamente o ponto de ligação entre a solução proposta e a etapa de Big Data e Ciência de Dados desenvolvida neste trabalho.

4. Seleção do conjunto de dados

A partir das necessidades identificadas, foi realizada a busca por conjuntos de dados públicos que apresentassem características compatíveis com o novo direcionamento do projeto.

Entre as possibilidades encontradas, foi selecionado o Semantic Drone Dataset, desenvolvido pela Graz University of Technology (TU Graz).

A escolha está relacionada principalmente ao fato de o conjunto possuir imagens aéreas obtidas por drones acompanhadas de informações de segmentação semântica, permitindo que diferentes regiões das imagens sejam associadas a classes específicas.

Dessa forma, o dataset apresenta características diretamente relacionadas à necessidade identificada para o desenvolvimento futuro do MVP.

5. Fonte e origem dos dados

O Semantic Drone Dataset foi desenvolvido pela Graz University of Technology (TU Graz) para pesquisas relacionadas à compreensão semântica de cenas obtidas por drones.

A fonte oficial do conjunto de dados é:

Semantic Drone Dataset — Graz University of Technology

https://ivc.tugraz.at/research-project/semantic-drone-dataset/

O conjunto também está disponível em uma versão distribuída pelo Kaggle:

https://www.kaggle.com/datasets/awsaf49/semantic-drone-dataset

Para fins de referência e documentação do projeto, a página oficial da TU Graz será considerada a principal fonte.

6. Caracterização do conjunto de dados

O Semantic Drone Dataset é composto por imagens aéreas de alta resolução obtidas por drones, destinadas principalmente a tarefas de segmentação semântica.

As imagens foram capturadas aproximadamente entre 5 e 30 metros de altura e possuem resolução de aproximadamente 6000 × 4000 pixels.

A documentação oficial apresenta 400 imagens públicas de treinamento e 200 imagens privadas de teste, além de diferentes classes utilizadas para representar elementos presentes nas cenas.

Entre as categorias representadas encontram-se elementos como árvores, grama, vegetação, solo, cascalho, pedras, água, áreas pavimentadas, telhados, paredes, cercas e outros objetos.

Característica	Informação
Dataset	Semantic Drone Dataset
Instituição	Graz University of Technology (TU Graz)
Tipo de dado	Imagens aéreas
Origem	Imagens obtidas por drones
Resolução	6000 × 4000 pixels
Altura aproximada	5 a 30 metros
Imagens públicas de treinamento	400
Imagens privadas de teste	200

Classes semânticas	20
Anotação	Segmentação em nível de pixel

7. Principais atributos dos dados

Por se tratar de um conjunto de dados baseado em imagens, seus atributos não possuem a mesma estrutura encontrada em bases tabulares tradicionais.

Nesse caso, as principais informações relevantes para o projeto estão relacionadas às características das imagens e de suas anotações.

Atributo	Descrição
Imagem aérea	Imagem capturada por drone representando uma determinada cena
Resolução	Dimensão da imagem em pixels
Pixel	Unidade básica utilizada na representação da imagem
Classe semântica	Categoria atribuída a determinado elemento da cena
Máscara de segmentação	Informação que identifica a classe correspondente às regiões/pixels da imagem
Altura de captura	Altura aproximada em que a imagem foi obtida
Cena	Ambiente representado pela imagem

Essas informações são importantes porque o objetivo do modelo não será apenas reconhecer uma imagem inteira, mas identificar quais regiões pertencem a cada classe.

8. Quantidade e volume dos dados

O conjunto possui 400 imagens públicas destinadas ao treinamento e 200 imagens privadas destinadas ao teste, conforme as informações disponibilizadas pela fonte oficial.

Além da quantidade de imagens, o volume de dados também deve ser considerado. A versão disponibilizada no Kaggle possui aproximadamente 4 GB, o que representa um volume significativo para um projeto acadêmico que posteriormente deverá realizar processamento e treinamento de modelos.

A resolução de 6000 × 4000 pixels também contribui para o elevado volume computacional das imagens.

Por esse motivo, o tamanho dos dados será considerado durante as etapas futuras de preparação e processamento.

9. Formato e preparação dos dados

O dataset é composto por imagens e informações de anotação utilizadas na segmentação semântica.

Como as imagens possuem alta resolução, poderá ser necessário realizar etapas de pré-processamento antes da utilização no treinamento do modelo.

Entre as possibilidades estão:

- Organização das imagens e respectivas máscaras;
- Padronização dos dados;
- Redução da resolução das imagens, caso necessário;
- Divisão entre treinamento, validação e teste;
- Adequação dos dados ao modelo utilizado;
- Aplicação de técnicas de aumento de dados, caso sejam necessárias.

A redução da resolução será considerada apenas como uma etapa de preparação, caso os testes indiquem que o tamanho original das imagens apresenta um custo computacional elevado.

O dataset original será preservado, enquanto versões processadas poderão ser utilizadas para o desenvolvimento do modelo.

10. Justificativa da escolha

A escolha do Semantic Drone Dataset está diretamente relacionada às necessidades identificadas para o novo direcionamento do projeto.

O GeoMap necessita de imagens aéreas obtidas por drones e de informações que permitam identificar diferentes elementos presentes nessas imagens. O dataset selecionado apresenta justamente imagens aéreas acompanhadas de informações de segmentação semântica.

Além disso, a presença de classes relacionadas ao solo, vegetação, pedras, áreas pavimentadas e estruturas permite trabalhar com diferentes elementos que possuem relação com a análise de terrenos proposta pelo projeto.

Outro fator relevante é a existência de uma quantidade significativa de imagens e a disponibilização pública do conjunto para utilização acadêmica e de pesquisa, respeitando suas respectivas condições de uso.

11. Relação entre os dados e o problema

Os dados selecionados representam a base necessária para transformar a proposta de automatização da análise de imagens em uma solução baseada em Inteligência Artificial.

O processo planejado pode ser representado da seguinte forma:

Problema identificado

↓

Análise manual de imagens aéreas

↓

Necessidade de automatização

↓

Imagens aéreas + máscaras de segmentação

↓

Preparação dos dados

↓

Treinamento do modelo

↓

Segmentação semântica

↓

Identificação dos elementos

↓

Auxílio à análise do terreno

Assim, as imagens não serão utilizadas apenas como exemplos visuais, mas como dados de treinamento e avaliação para que o modelo possa aprender a diferenciar os elementos presentes nas cenas.

12. Limitações e desafios iniciais

O conjunto de dados apresenta algumas características que deverão ser consideradas durante o desenvolvimento.

A primeira delas está relacionada à alta resolução das imagens, que resulta em maior necessidade de memória, armazenamento e capacidade de processamento.

O volume de aproximadamente 4 GB da versão disponibilizada no Kaggle também representa um desafio para o processamento em equipamentos com recursos computacionais limitados.

Por esse motivo, poderá ser necessário realizar etapas de pré-processamento, incluindo a redução da resolução das imagens ou utilização de subconjuntos dos dados, sem alterar os arquivos originais.

Outra limitação está relacionada à diferença entre as características das imagens disponíveis no dataset e as imagens que poderão ser obtidas futuramente em situações reais. Diferenças de ambiente, iluminação, altitude, equipamentos e condições de captura podem influenciar o desempenho do modelo.

Também deverão ser observadas as condições de uso e distribuição estabelecidas pelos responsáveis pelo dataset. Por esse motivo, o conjunto original não será armazenado diretamente no repositório GitHub.

13. Considerações finais

O presente trabalho dá continuidade ao projeto inicialmente desenvolvido na disciplina de Inteligência Artificial, mantendo o problema e o contexto original, mas incorporando o novo direcionamento definido para as etapas seguintes do projeto.

A priorização da segmentação semântica de imagens aéreas estabelece uma necessidade específica de dados, levando à seleção do Semantic Drone Dataset como base para as futuras etapas de desenvolvimento.

A análise realizada neste trabalho permite compreender quais dados serão necessários, suas características, limitações e sua relação com o problema proposto.

Com essa etapa concluída, o projeto passa a possuir uma base de dados definida para as próximas fases, nas quais poderão ser realizadas a preparação das imagens, o desenvolvimento do modelo de segmentação e a avaliação dos resultados.

TED 02 – LIMPEZA, SANEAMENTO E ANÁLISE EXPLORATÓRIA DOS DADOS

15. Limpeza, Saneamento e Análise Exploratória

15.1 Continuidade do projeto

Nesta segunda etapa de Big Data, o projeto avança para a inspeção, preparação, limpeza e análise exploratória do conjunto de dados selecionado. O objetivo é compreender melhor as características da base, identificar possíveis problemas de qualidade e realizar os tratamentos necessários para torná-la mais adequada às etapas posteriores do projeto.

15.2 Inspeção inicial do conjunto de dados

Durante a inspeção inicial do conjunto de dados selecionado na TED 01, verificou-se que as imagens aéreas apresentam dimensões de 6000 × 4000 pixels, correspondendo a aproximadamente 24 milhões de pixels por imagem (24 MP).

Também foi observado que o tamanho dos arquivos varia aproximadamente entre 8MB e 12MB por imagem.

A elevada resolução proporciona uma grande quantidade de detalhes visuais, característica importante para o objetivo do GeoMap, uma vez que a solução pretende trabalhar com imagens aéreas e posteriormente realizar a identificação de diferentes elementos presentes no terreno.

Entretanto, essa característica também representa uma maior demanda de armazenamento, memória e processamento computacional. O processamento de imagens com dimensões muito elevadas pode aumentar o custo computacional das etapas posteriores, principalmente quando várias imagens precisarem ser processadas simultaneamente ou utilizadas no treinamento de modelos de Inteligência Artificial.

Dessa forma, a resolução das imagens foi identificada como um dos primeiros aspectos que deverá ser considerado durante o processo de preparação dos dados.

15.3 Problema identificado

A inspeção inicial permitiu identificar como principal ponto de atenção, nesta etapa, as dimensões elevadas das imagens.

As imagens de 6000 × 4000 pixels possuem uma quantidade significativa de informações visuais, mas também exigem maior capacidade computacional para armazenamento, carregamento, processamento e utilização nas etapas futuras do projeto.

15.4 Tratamento e preparação dos dados

Como tratamento inicial, foi realizado o redimensionamento das imagens. O objetivo desse procedimento não foi simplesmente diminuir o tamanho dos arquivos, mas encontrar um equilíbrio entre a redução da demanda computacional e a preservação das características visuais importantes para o projeto.

As 400 imagens originais, com resolução de **6000 × 4000 pixels**, foram redimensionadas para **1280 × 853 pixels**, mantendo a proporção aproximada de **3:2**. Essa resolução foi escolhida de modo a reduzir significativamente a quantidade de dados a ser processada, mantendo ainda uma qualidade visual adequada para a identificação dos elementos presentes nas imagens aéreas.

O redimensionamento foi realizado por meio de um script desenvolvido em **Python**, utilizando a biblioteca **Pillow** e o método de interpolação **Lanczos**. As imagens foram convertidas para o espaço de cores **RGB** e armazenadas no formato **JPEG**, com qualidade 90 e otimização do arquivo.

As imagens originais não foram modificadas. As versões processadas foram armazenadas separadamente na pasta **"processed"**, permitindo manter os dados originais preservados para eventuais comparações ou necessidades futuras.

Ao final do tratamento, todas as **400 imagens foram processadas com sucesso**, sem ocorrência de erros. O tamanho total do conjunto foi reduzido de **3.892,20 MB para 148,04 MB**, correspondendo a uma redução de **96,20% no espaço de armazenamento**.

15.5 Descrição da base após o tratamento

Após o processo de preparação, a base passou a ser composta por **400 imagens**, todas armazenadas no formato **JPEG (.jpg)** e com resolução padronizada de **1280 × 853 pixels**.

A análise da base processada confirmou que todas as imagens apresentam a mesma resolução, não sendo identificadas diferenças dimensionais entre os arquivos. Essa

padronização facilita a utilização do conjunto nas etapas posteriores de processamento e análise, pois estabelece uma estrutura uniforme para todas as imagens.

Em relação ao armazenamento, o conjunto processado possui **148,04 MB** no total. O tamanho médio de cada imagem é de aproximadamente **0,37 MB**, enquanto o menor arquivo possui **0,21 MB** e o maior possui **0,55 MB**.

A padronização das dimensões e a redução do tamanho dos arquivos resultaram em uma base mais uniforme e significativamente mais compacta, mantendo as 400 imagens disponíveis para as próximas etapas do projeto.

15.6 Estatísticas descritivas

A análise estatística foi realizada sobre os pixels das 400 imagens processadas, totalizando **436.736.000 pixels analisados**. As imagens apresentam três canais de cor no padrão RGB, sendo possível calcular medidas descritivas para os canais vermelho (R), verde (G) e azul (B).

A média de intensidade dos pixels foi de **113,52 para o canal vermelho**, **112,97 para o canal verde** e **102,38 para o canal azul**. Esses valores representam a intensidade média de cada canal considerando todo o conjunto de imagens analisado.

O desvio padrão apresentou valores de **56,22 no canal vermelho**, **54,46 no canal verde** e **58,12 no canal azul**. A presença de valores relativamente elevados de desvio padrão indica uma distribuição diversificada das intensidades dos pixels, característica compatível com imagens aéreas que apresentam diferentes elementos, superfícies e condições de iluminação.

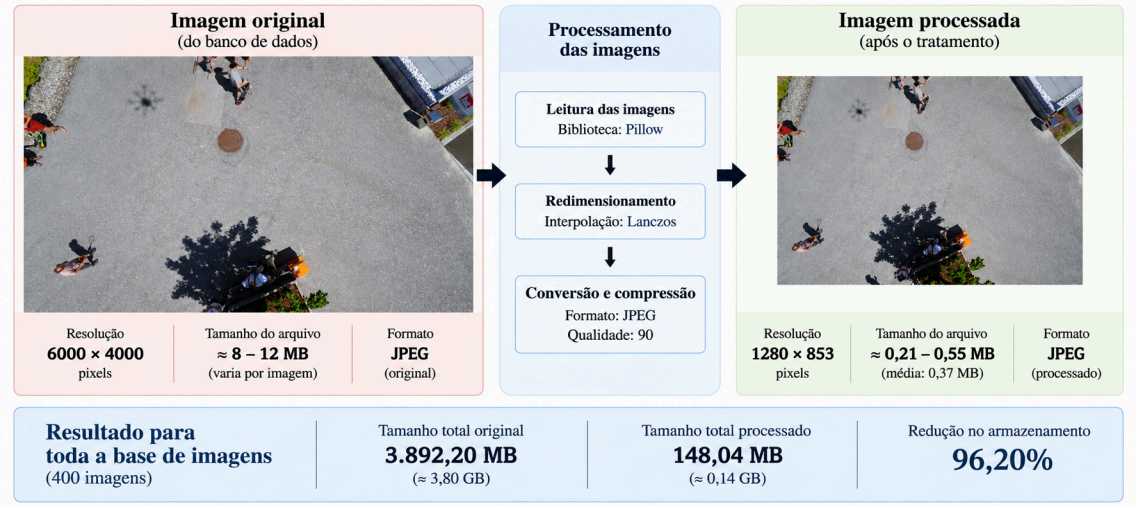
Os valores mínimos observados foram **0** nos três canais, enquanto os valores máximos alcançaram **255** nos três canais, abrangendo toda a faixa possível de intensidade de uma imagem RGB de 8 bits.

A luminosidade média aproximada do conjunto foi de **111,93**. Esse resultado fornece uma referência geral sobre a intensidade luminosa das imagens processadas e servirá como base para as análises visuais e gráficas das próximas etapas.

15.6 Gráficos e visualizações

Para complementar a análise dos dados, foram elaboradas visualizações que permitem observar tanto o processo de tratamento aplicado às imagens quanto as características estatísticas da base resultante. A primeira visualização apresenta, de forma comparativa, uma imagem antes e depois do processamento, evidenciando a redução da resolução e do tamanho do arquivo, enquanto as visualizações seguintes apresentam as características estatísticas dos pixels do conjunto processado.

Exemplo do processo de redimensionamento das imagens do conjunto de dados.



15.8 Análise dos principais resultados

Os resultados obtidos após o tratamento demonstram que o processo de preparação produziu uma redução significativa no volume de dados, sem comprometer visualmente a qualidade das imagens para a continuidade do projeto.

A redução da resolução de **6000 × 4000 para 1280 × 853 pixels** diminuiu consideravelmente a quantidade de informações que precisa ser armazenada e processada em cada imagem. Como consequência, o tamanho total da base passou de **3.892,20 MB para 148,04 MB**, representando uma redução de **96,20% no armazenamento**.

Apesar da redução significativa, as imagens processadas mantiveram a proporção original e apresentaram qualidade visual considerada adequada após a inspeção. Os principais elementos presentes nas cenas continuam identificáveis, o que é importante para as etapas futuras relacionadas ao processamento e à segmentação das imagens.

Outro resultado relevante foi a padronização da base. As **400 imagens** passaram a apresentar a mesma resolução de **1280 × 853 pixels**, facilitando sua utilização em operações posteriores que dependam de dimensões uniformes.

Dessa forma, o tratamento realizado atende ao objetivo inicial desta etapa: tornar o conjunto de dados mais compacto e uniforme, reduzindo a demanda de armazenamento e processamento sem eliminar as características visuais necessárias para a continuidade do GeoMap.

15.9 Padrões, tendências e relações identificadas

A análise da base após o tratamento permitiu identificar uma relação direta entre a resolução das imagens e o volume de armazenamento necessário. A redução das dimensões de **6000 × 4000**

pixels para 1280 × 853 pixels resultou em uma diminuição expressiva do tamanho dos arquivos, mantendo a mesma proporção de aproximadamente 3:2.

Também foi identificado um padrão de **uniformização da base**, uma vez que todas as 400 imagens processadas passaram a apresentar exatamente a mesma resolução e o mesmo formato de arquivo. Essa padronização reduz diferenças estruturais entre os dados e facilita sua utilização em etapas posteriores de processamento.

Outro padrão observado foi a redução consistente do tamanho dos arquivos processados. Os arquivos apresentaram tamanhos entre **0,21 MB e 0,55 MB**, com média de aproximadamente **0,37 MB**, demonstrando que o conjunto tratado passou a apresentar um volume de armazenamento significativamente menor e mais uniforme.

A relação observada entre redução da resolução e redução do armazenamento está diretamente relacionada ao objetivo do tratamento. Ao diminuir a quantidade de pixels de cada imagem, também foi reduzida a quantidade de dados necessária para armazená-las e processá-las, contribuindo para uma base mais adequada às etapas computacionais posteriores.

15.10 Relação dos resultados com o problema e o MVP

Os resultados obtidos nesta etapa estão diretamente relacionados ao problema identificado no projeto GeoMap, que envolve o processamento de imagens aéreas e a necessidade de tornar os dados mais adequados para utilização computacional.

O tratamento realizado permitiu transformar o conjunto original em uma base mais compacta e padronizada, reduzindo de forma significativa o volume de dados sem eliminar visualmente os elementos necessários para a continuidade do projeto. Essa característica é relevante para o MVP, que prevê o uso de técnicas de processamento de imagens e, posteriormente, de segmentação semântica para identificar diferentes elementos presentes nas imagens aéreas.

A redução do volume de dados também contribui para tornar as etapas futuras mais viáveis do ponto de vista computacional. Operações de leitura, armazenamento, processamento e treinamento de modelos podem ser realizadas sobre uma base significativamente menor, mantendo as imagens em uma resolução padronizada.

Dessa forma, o tratamento realizado nesta etapa estabelece uma base de dados mais adequada para a continuidade do desenvolvimento do MVP. A preparação das imagens não representa o resultado final do GeoMap, mas constitui uma etapa necessária para que as próximas fases de processamento e análise possam ser executadas de maneira mais organizada e eficiente.

TED 03 – Modelagem Preditiva e Machine Learning

16. Modelagem de Machine Learning

16.1 Definição do problema de Machine Learning

O projeto GeoMap tem como objetivo auxiliar a interpretação de imagens aéreas obtidas por drones, reduzindo o trabalho manual necessário para identificar os diferentes elementos presentes em terrenos. Conforme definido nas etapas anteriores, a solução proposta prioriza o desenvolvimento de um sistema de segmentação semântica de imagens aéreas, capaz de identificar e classificar os elementos presentes nas cenas.

Nesse contexto, o problema de Machine Learning consiste em desenvolver um modelo capaz de realizar a segmentação semântica de imagens aéreas, associando os pixels das imagens às respectivas classes semânticas. Entre os elementos de interesse do projeto estão solo, vegetação, grama, pedras, cascalho, árvores, áreas pavimentadas e construções, além de outros elementos representados no conjunto de dados selecionado.

Para o desenvolvimento dessa solução, será utilizado como referência o *Semantic Drone Dataset*, selecionado na TED 01 e analisado e preparado na TED 02. O conjunto de dados possui imagens aéreas acompanhadas de informações de segmentação, que poderão ser utilizadas para ensinar o modelo a reconhecer os diferentes elementos presentes nas imagens.

A modelagem deverá considerar as características da base preparada, incluindo a resolução padronizada das imagens e a necessidade de utilizar suas respectivas máscaras de segmentação. A disponibilidade e a compatibilidade desses arquivos deverão ser verificadas antes do treinamento, garantindo que os dados de entrada estejam corretamente associados às informações utilizadas como referência durante o aprendizado.

A solução será considerada inicialmente funcional quando o modelo conseguir receber uma imagem aérea e produzir uma representação segmentada, identificando as regiões correspondentes às classes aprendidas. O desempenho dessa identificação será avaliado por meio de métricas adequadas à segmentação semântica, permitindo analisar a qualidade dos resultados e suas limitações.

Dessa forma, esta etapa dá continuidade ao trabalho desenvolvido nas TEDs anteriores, avançando da seleção, preparação e análise dos dados para o desenvolvimento experimental de um modelo de Machine Learning relacionado ao objetivo do GeoMap. Os resultados obtidos servirão de base para avaliar a viabilidade da abordagem e orientar a evolução do MVP de Inteligência Artificial.

16.2 Tipo de abordagem adotada

Para o desenvolvimento do modelo, será utilizada a abordagem de Aprendizado Supervisionado (*Supervised Learning*), aplicada à tarefa de segmentação de imagens por meio de técnicas de visão computacional.

A escolha dessa abordagem está relacionada às características do problema definido no projeto GeoMap, que consiste em identificar diferentes elementos presentes em imagens aéreas obtidas por drones. Nesse processo, o modelo utiliza imagens acompanhadas de anotações previamente identificadas, permitindo aprender a reconhecer e delimitar regiões correspondentes às classes de interesse.

Para a implementação, o projeto utiliza a arquitetura YOLO11-Seg, disponibilizada pela biblioteca Ultralytics. Essa arquitetura trabalha com segmentação de instâncias (*Instance Segmentation*), permitindo identificar e delimitar objetos presentes nas imagens por meio de máscaras individuais.

Embora o direcionamento inicial do TED 02 tenha priorizado a segmentação semântica, a implementação desenvolvida no repositório de Inteligência Artificial utiliza a segmentação de instâncias como abordagem técnica. Essa escolha permite trabalhar com a identificação e delimitação de elementos presentes nas imagens aéreas, mantendo relação direta com o objetivo de automatizar a interpretação visual dos terrenos.

No desenvolvimento atual, as categorias originais do conjunto de dados são agrupadas em três classes principais: construção, vegetação e via. Essa organização busca concentrar os elementos de interesse do projeto em categorias mais abrangentes, facilitando a identificação das principais estruturas presentes nas imagens.

Dessa forma, o GeoMap adota o Aprendizado Supervisionado por meio de segmentação de instâncias com YOLO11-Seg, utilizando imagens e suas respectivas anotações como referência para o treinamento. A abordagem será avaliada experimentalmente, considerando sua capacidade de identificar os elementos de interesse e suas possíveis contribuições para a evolução do MVP de Inteligência Artificial.

16.3 Preparação dos dados

A preparação dos dados para a modelagem de Machine Learning dá continuidade aos procedimentos realizados na TED 02 e incorpora as transformações necessárias para adequar o conjunto de dados à arquitetura de segmentação utilizada no projeto.

Na etapa anterior, as 400 imagens do Semantic Drone Dataset foram redimensionadas de 6000 × 4000 para 1280 × 853 pixels, mantendo sua proporção aproximada de 3:2. O processamento foi realizado utilizando Python e a biblioteca Pillow, com interpolação Lanczos, conversão para o espaço de cores RGB e armazenamento no formato JPEG, com qualidade 90. Esse procedimento reduziu o volume total da base de aproximadamente 3.892,20 MB para 148,04 MB, representando uma redução de 96,20% no armazenamento.

Para adequar os dados ao modelo YOLO11-Seg, foi desenvolvido no repositório de Inteligência Artificial o scriptw `src/preparar_dataset.py`, responsável por realizar a conversão das anotações de segmentação para o formato utilizado pela arquitetura. O procedimento contempla a leitura das imagens e de suas respectivas máscaras, identificadas por nomes correspondentes, permitindo relacionar corretamente cada imagem às informações de referência.

O script também realiza o agrupamento de categorias originais do dataset em três classes principais definidas para o projeto: construção, vegetação e via. Esse agrupamento tem como objetivo concentrar os elementos de interesse em categorias mais abrangentes, relacionadas à proposta inicial do GeoMap.

Após a identificação das regiões correspondentes a cada classe nas máscaras, o procedimento utiliza operações de processamento de imagens para extrair seus contornos e representá-los como polígonos. Essas informações são convertidas para o formato YOLO-seg, no qual cada anotação contém o identificador da classe e as coordenadas normalizadas dos pontos que delimitam a região correspondente.

O script também prevê o redimensionamento das imagens para que sua maior dimensão não ultrapasse 1024 pixels, além da divisão dos dados em três subconjuntos: treinamento, validação e teste, utilizando proporções de 70%, 20% e 10%, respectivamente. A divisão é realizada por imagem, com utilização de uma semente fixa para favorecer a reprodutibilidade do procedimento.

É importante destacar que a preparação realizada na TED 02 e a conversão específica para o formato YOLO-seg representam etapas distintas do processamento. A primeira teve como objetivo reduzir o volume de armazenamento e padronizar as imagens. A segunda foi desenvolvida para transformar as imagens e suas anotações em uma estrutura compatível com o treinamento do modelo de segmentação.

Dessa forma, os procedimentos implementados estabelecem o fluxo necessário para transformar o conjunto de dados original em uma estrutura adequada à modelagem, mantendo a correspondência entre as imagens e suas respectivas anotações. A geração e a conferência do conjunto final de treinamento deverão ser verificadas durante a execução dos experimentos.

16.4 Seleção das variáveis e definição das classes

Por se tratar de um problema de segmentação de instâncias aplicado à visão computacional, as variáveis utilizadas pelo modelo correspondem principalmente às informações visuais presentes nas imagens aéreas. Dessa forma, as imagens em formato RGB constituem os dados de entrada, fornecendo informações de cor, textura, formas e características espaciais que auxiliam o modelo na identificação dos elementos presentes nas cenas.

Como referência para o aprendizado supervisionado, são utilizadas as anotações associadas às imagens, que indicam a localização e os contornos dos objetos pertencentes às classes de interesse. Essas informações são convertidas para o formato de segmentação compatível com a

arquitetura YOLO11-Seg, permitindo que o modelo aprenda a identificar e delimitar as instâncias durante o treinamento.

Na implementação atual, as categorias originais do Semantic Drone Dataset são agrupadas em três classes principais:

- **Construção:** representa elementos relacionados a edificações e estruturas construídas, como telhados e paredes.
- **Vegetação:** reúne elementos naturais de cobertura vegetal, como árvores, grama e outras formas de vegetação.
- **Via:** representa superfícies destinadas à circulação e áreas pavimentadas.

A definição dessas classes busca reduzir a quantidade de categorias utilizadas originalmente no conjunto de dados, concentrando a identificação nos elementos considerados mais relevantes para a interpretação de terrenos pelo GeoMap.

Assim, as imagens RGB são utilizadas como variáveis de entrada, enquanto as máscaras e anotações de objetos representam as informações de referência utilizadas no aprendizado supervisionado. As três categorias definidas constituem as classes que o modelo deverá reconhecer e segmentar nas imagens aéreas.

16.5 Técnicas de Machine Learning utilizadas

Para a implementação do modelo de reconhecimento de elementos em imagens aéreas, foi utilizada a arquitetura **YOLO11-Seg**, disponibilizada pela biblioteca Ultralytics. Essa arquitetura pertence à família YOLO (You Only Look Once) e possui recursos de detecção e segmentação de instâncias, permitindo identificar objetos e gerar máscaras que delimitam suas respectivas regiões nas imagens.

A técnica utiliza uma rede neural treinada de forma supervisionada, na qual as imagens são apresentadas juntamente com suas anotações correspondentes. Durante o treinamento, o modelo ajusta seus parâmetros para aprender padrões visuais que possibilitem reconhecer as classes definidas no projeto.

No GeoMap, a implementação utiliza a variante `yolo11s-seg.pt` como modelo de referência, conforme a configuração existente no projeto de Inteligência Artificial. Também existe a possibilidade de utilização da variante `yolo11n-seg.pt`, que apresenta uma arquitetura mais leve.

O processamento permite que, após o treinamento, uma imagem aérea seja fornecida ao modelo para que ele identifique as instâncias pertencentes às classes construção, vegetação e via, produzindo máscaras que representam os elementos reconhecidos.

A implementação utiliza recursos da biblioteca Ultralytics, juntamente com ferramentas de processamento de imagens, como OpenCV e NumPy, para apoiar as etapas de preparação dos dados e execução do modelo.

Dessa maneira, a técnica escolhida permite aplicar redes neurais à interpretação automatizada de imagens aéreas, constituindo a base da solução de segmentação desenvolvida para o GeoMap.

16.6 Justificativa da técnica escolhida

A escolha da arquitetura YOLO11-Seg está relacionada à necessidade de identificar e delimitar automaticamente elementos presentes em imagens aéreas obtidas por drones. Como o GeoMap busca auxiliar a interpretação visual de terrenos, é importante utilizar uma técnica capaz de reconhecer diferentes objetos e representar suas regiões de forma visual.

A segmentação de instâncias oferece essa possibilidade ao produzir máscaras individuais para os objetos identificados, permitindo distinguir e delimitar elementos pertencentes às classes construção, vegetação e via. Esse recurso é relevante para o projeto, pois possibilita uma representação mais detalhada dos componentes presentes nas imagens do que uma classificação geral da cena.

Outro fator considerado é a utilização da biblioteca Ultralytics, que disponibiliza modelos pré-treinados, ferramentas para preparação dos dados, treinamento, avaliação e inferência. Essa estrutura facilita o desenvolvimento experimental e permite utilizar diferentes configurações de modelos conforme os recursos computacionais disponíveis.

A existência de variantes como YOLO11n-Seg e YOLO11s-Seg também permite considerar diferentes relações entre capacidade de processamento e desempenho, aspecto importante para um projeto que pretende trabalhar com imagens aéreas e evoluir para uma aplicação prática.

Portanto, a escolha da YOLO11-Seg foi motivada por sua capacidade de realizar segmentação de instâncias, pela disponibilidade de ferramentas de desenvolvimento e pela possibilidade de adaptação às necessidades do GeoMap. Sua adequação definitiva deverá ser analisada por meio dos resultados experimentais, considerando as métricas de avaliação e as limitações encontradas durante os testes.

16.7 Processo de treinamento e avaliação do modelo

O processo de desenvolvimento do modelo foi estruturado em etapas, contemplando a preparação das imagens e anotações, a organização dos dados, o treinamento da rede neural e a avaliação dos resultados obtidos.

Na implementação disponível no projeto de Inteligência Artificial, o script `src/preparar_dataset.py` é responsável por organizar os pares de imagens e máscaras, agrupar as categorias originais nas três classes definidas para o GeoMap e converter as anotações para o formato de segmentação utilizado pela arquitetura YOLO11-Seg. O processo também contempla a divisão dos dados em conjuntos de treinamento, validação e teste, seguindo a proporção de 70%, 20% e 10%, respectivamente.

Após a preparação dos dados, o script `src/train.py` disponibiliza a estrutura necessária para executar o treinamento do modelo utilizando a biblioteca Ultralytics. Nessa etapa, a rede

neural utiliza as imagens e suas respectivas anotações para ajustar seus parâmetros e aprender a identificar os elementos presentes nas cenas.

A avaliação dos resultados é apoiada pelo script `src/evaluate.py`, enquanto o script `src/predict.py` permite realizar inferências em novas imagens, produzindo as máscaras de segmentação correspondentes às classes reconhecidas.

Além da estrutura de treinamento e avaliação disponível no código, foi documentada uma avaliação experimental realizada em 29 de outubro de 2026, utilizando pesos de um modelo previamente treinado e dez imagens próprias obtidas por drone. Essa avaliação permitiu observar o comportamento do modelo em imagens diferentes das utilizadas como referência durante o desenvolvimento.

É importante destacar que essa avaliação experimental com imagens próprias não corresponde aos resultados de uma nova execução de treinamento nem deve ser confundida com a avaliação oficial do conjunto de teste separado na preparação dos dados.

Dessa forma, o processo contempla a organização dos dados, a estrutura de treinamento, a avaliação quantitativa e a realização de previsões em imagens aéreas. A documentação dos experimentos permite acompanhar a evolução do modelo e identificar as etapas que ainda necessitam de execução ou aprimoramento.

16.8 Métricas utilizadas na avaliação

Para avaliar o desempenho do modelo de segmentação de instâncias, são utilizadas métricas que permitem analisar a correspondência entre as regiões identificadas pelo modelo e as máscaras de referência. Essas medidas ajudam a compreender a capacidade do algoritmo de reconhecer e delimitar corretamente os elementos presentes nas imagens aéreas.

Entre as métricas utilizadas na avaliação estão:

- **Intersection over Union (IoU):** mede a sobreposição entre a máscara prevista pelo modelo e a máscara de referência. Seu resultado varia de 0 a 1, sendo que valores mais próximos de 1 indicam maior correspondência entre as regiões.
- **Dice Coefficient:** avalia a similaridade entre a máscara prevista e a máscara de referência, considerando a proporção de pixels compartilhados entre ambas. Valores mais elevados indicam maior precisão na delimitação dos elementos.
- **Mean Intersection over Union (mIoU):** representa a média dos valores de IoU calculados para as classes avaliadas, permitindo observar o desempenho geral do modelo.
- **Mean Dice (mDice):** corresponde à média dos valores de Dice entre as classes, oferecendo uma visão geral da qualidade das segmentações produzidas.

Essas métricas são importantes porque a avaliação de um modelo de segmentação não deve considerar apenas se determinado objeto foi reconhecido, mas também se sua delimitação corresponde adequadamente à região esperada.

No GeoMap, a análise considera as classes construção, vegetação e via, permitindo observar o desempenho individual de cada categoria e identificar possíveis diferenças na capacidade de reconhecimento do modelo.

Dessa maneira, a utilização dessas métricas fornece uma base quantitativa para interpretar os resultados experimentais, identificar dificuldades na segmentação e orientar possíveis melhorias na solução desenvolvida.

16.9 Resultados obtidos

A avaliação experimental do modelo foi realizada em 29 de outubro de 2026, utilizando dez imagens próprias obtidas por drone. Para essa análise, foram utilizados pesos de um modelo previamente treinado, com o objetivo de verificar seu comportamento diante de imagens aéreas diferentes daquelas utilizadas como referência durante o desenvolvimento.

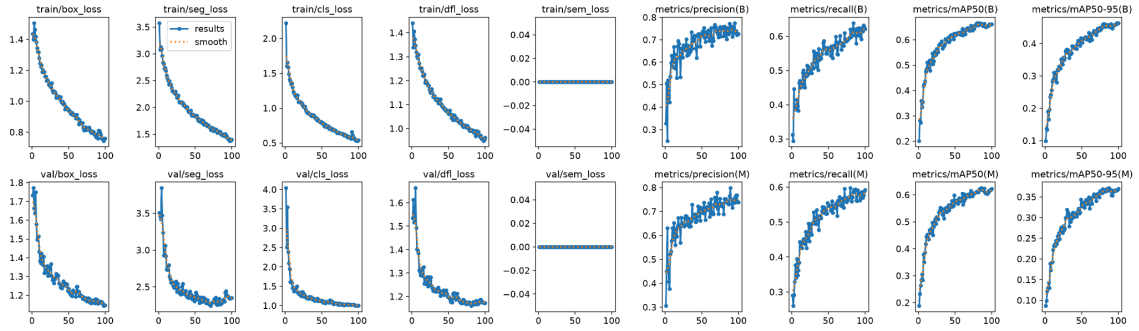


Figura 2 – Evolução das métricas durante o treinamento do modelo YOLO11s-seg.

Fonte: Elaborado pelos autores (2026).

A Figura X apresenta o histórico de treinamento do modelo YOLO11s-seg ao longo de 100 épocas, permitindo acompanhar a evolução do processo de aprendizagem. Os gráficos demonstram a redução progressiva das perdas associadas ao treinamento e à validação, indicando os ajustes realizados pelo modelo ao longo das iterações. Também é possível observar a evolução das métricas de precisão, revocação e precisão média (mAP), tanto para as detecções quanto para as máscaras de segmentação. Esse acompanhamento permite analisar o comportamento do modelo durante o treinamento e identificar possíveis dificuldades de aprendizagem, constituindo uma etapa importante para o desenvolvimento da solução proposta pelo GeoMap.

Os resultados gerais obtidos na avaliação experimental com as dez imagens próprias foram:

Métrica	Resultado
Mean Intersection over Union (mIoU)	51,77%
Mean Dice Coefficient (mDice)	67,59%

A análise individual por classe apresentou os seguintes resultados:

Classe	IoU	Dice
Construção	52,56%	68,90%
Vegetação	64,15%	78,16%
Via	38,60%	55,70%

Além dos indicadores quantitativos, a análise dos resultados também pode ser complementada pela observação visual das previsões produzidas pelo modelo. Essa representação permite compreender de maneira mais direta como a inteligência artificial identifica e delimita os elementos presentes nas imagens aéreas, relacionando os resultados numéricos ao funcionamento prático da solução.

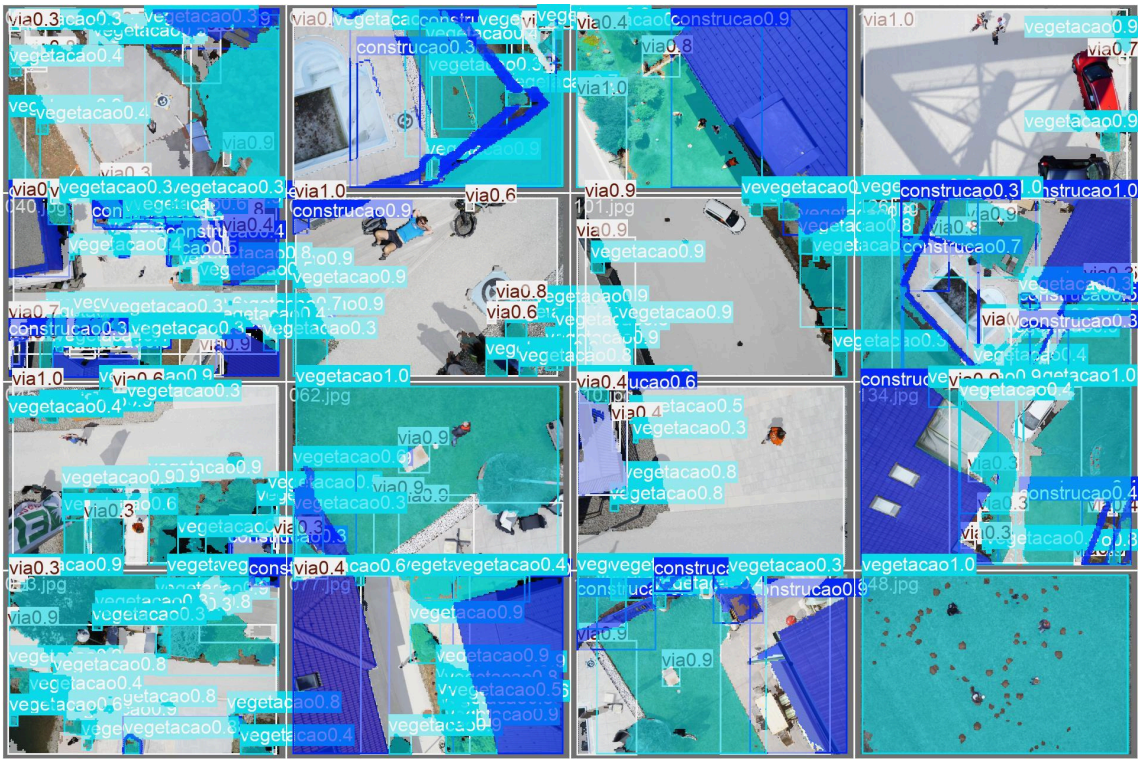


Figura 3 – Exemplos de segmentação das classes construção, vegetação e via em imagens aéreas.

Fonte: Elaborado pelos autores (2026).

Conforme apresentado na Figura X, o modelo realiza a identificação das categorias definidas durante seu treinamento, representando as regiões reconhecidas por meio de máscaras coloridas sobre as imagens aéreas. As marcações permitem visualizar a distribuição espacial dos elementos identificados, evidenciando a aplicação da segmentação semântica na interpretação de imagens obtidas por drones. Observa-se que o processamento possibilita distinguir diferentes elementos presentes nas cenas, embora possam ocorrer sobreposições, identificações incompletas e confusões entre categorias. Dessa forma, a representação visual complementa a avaliação quantitativa, permitindo compreender tanto as possibilidades de aplicação quanto os desafios ainda existentes no desenvolvimento do GeoMap.

Os resultados demonstram diferenças no desempenho do modelo entre as categorias avaliadas. A classe vegetação apresentou os melhores valores de IoU e Dice, indicando maior correspondência entre as máscaras previstas e as referências utilizadas na avaliação.

A classe construção apresentou resultados intermediários, enquanto a classe via obteve os menores índices, indicando maior dificuldade do modelo para identificar e delimitar corretamente esse tipo de elemento nas imagens analisadas.

É importante destacar que os valores apresentados correspondem exclusivamente à avaliação experimental realizada com dez imagens próprias. Portanto, não representam uma avaliação definitiva da capacidade de generalização do modelo nem substituem os resultados de uma avaliação realizada sobre o conjunto de testes separado durante a preparação dos dados.

16.10 Interpretação dos resultados

Os resultados da avaliação experimental permitem observar que o modelo apresenta diferentes níveis de desempenho conforme a classe analisada. A vegetação obteve os melhores resultados, com IoU de 64,15% e Dice de 78,16%, indicando maior correspondência entre as regiões segmentadas pelo modelo e as máscaras de referência. Esse resultado sugere que as características visuais dessa categoria foram reconhecidas com maior consistência nas imagens avaliadas.

A classe construção apresentou IoU de 52,56% e Dice de 68,90%, demonstrando um desempenho intermediário. Apesar de conseguir identificar parte das estruturas presentes nas imagens, o modelo ainda apresenta dificuldades na delimitação precisa de determinadas regiões.

Já a classe via obteve IoU de 38,60% e Dice de 55,70%, representando o menor desempenho entre as categorias. Esse resultado indica maior dificuldade na identificação e delimitação das superfícies pavimentadas. Uma possível explicação está na semelhança visual entre determinadas vias, telhados e outras superfícies, o que pode ocasionar confusões durante a segmentação.

Considerando os resultados gerais, o mIoU de 51,77% e o mDice de 67,59% demonstram que o modelo conseguiu produzir segmentações com correspondência parcial em relação às referências utilizadas. Entretanto, os valores também evidenciam oportunidades de melhoria, principalmente na identificação da classe via.

É importante considerar que essa interpretação está limitada à avaliação realizada com dez imagens próprias, cujas anotações foram produzidas com auxílio de ferramentas de segmentação automática (SAM) e revisão humana. Portanto, os resultados representam uma análise experimental inicial e não permitem afirmar, isoladamente, que o modelo apresenta o mesmo desempenho em diferentes regiões, condições de iluminação, altitudes ou características de terreno.

16.11 Limitações e dificuldades encontradas

Durante o desenvolvimento e a avaliação experimental do modelo, foram identificadas algumas limitações que precisam ser consideradas na análise dos resultados e na continuidade do projeto GeoMap.

Um dos aspectos importantes está relacionado à qualidade e à diversidade das anotações utilizadas como referência. As máscaras das imagens próprias foram produzidas com auxílio de ferramentas de segmentação automática (SAM) e passaram por revisão humana. Apesar desse procedimento contribuir para a elaboração das referências, possíveis imprecisões nas delimitações podem influenciar os valores das métricas calculadas.

Também foram observadas dificuldades na distinção entre elementos visualmente semelhantes. Um exemplo identificado durante a avaliação foi a confusão entre determinadas regiões de telhados e vias, indicando que características como cor, textura e aparência da superfície podem dificultar a identificação correta das classes.

A classe via apresentou os menores resultados entre as categorias avaliadas, evidenciando a necessidade de aprimorar sua representação nos dados de treinamento e ampliar a diversidade de exemplos utilizados pelo modelo.

Além disso, a utilização de apenas três classes principais simplifica a representação dos elementos presentes nas imagens. Embora essa organização facilite o desenvolvimento inicial, ela não contempla toda a diversidade de componentes existentes em um terreno, como solo exposto, pedras, cascalho e outros elementos naturais.

Por fim, os resultados obtidos ainda possuem caráter experimental. A necessidade de avaliar o modelo em diferentes terrenos e condições de captura deve ser considerada antes de conclusões definitivas sobre sua capacidade de generalização.

Diante dessas limitações, torna-se necessário aprimorar as anotações, investigar as confusões entre classes e realizar novos experimentos para aumentar a confiabilidade da solução desenvolvida.

16.12 Relação dos resultados com o projeto GeoMap

O desenvolvimento do modelo de segmentação de instâncias representa um avanço importante para o objetivo do GeoMap, pois permite aplicar técnicas de Inteligência Artificial na identificação automatizada de elementos presentes em imagens aéreas obtidas por drones.

A identificação das classes construção, vegetação e via contribui para organizar visualmente as informações presentes nas imagens, facilitando a interpretação das características do terreno. Por meio das máscaras produzidas pelo modelo, é possível observar a localização e a delimitação dos elementos reconhecidos, reduzindo a necessidade de identificação exclusivamente manual.

Os resultados experimentais demonstram a possibilidade de utilizar o modelo como recurso de apoio à análise visual de imagens aéreas. Entretanto, as limitações identificadas indicam que sua utilização deve ser considerada como uma ferramenta auxiliar, não substituindo a análise e a interpretação realizadas por profissionais da área de engenharia.

A implementação também estabelece uma base tecnológica para futuras evoluções do GeoMap, permitindo ampliar as categorias reconhecidas, aprimorar a qualidade das segmentações e integrar os resultados a outras funcionalidades do sistema.

Dessa forma, a aplicação de Machine Learning aproxima o projeto de seu objetivo principal: desenvolver uma solução computacional capaz de auxiliar a interpretação de terrenos por meio do processamento automatizado de imagens aéreas.

REFERÊNCIAS

BRADSKI, G.; KAEHLER, A. Learning OpenCV: Computer Vision with the OpenCV Library. Sebastopol: O'Reilly Media, 2008.

GONZALEZ, R. C.; WOODS, R. E. Processamento digital de imagens. 3. ed. São Paulo: Pearson Prentice Hall, 2010.

HARRIS, C. R. et al. Array programming with NumPy. Nature, v. 585, n. 7825, p. 357-362, 2020.

LILLESAND, T.; KIEFER, R. W.; CHIPMAN, J. Remote sensing and image interpretation. 7. ed. Hoboken: John Wiley & Sons, 2015.

OPENDRONEMAP. WebODM Documentation. Disponível em: https://docs.opendronemap.org. Acesso em: 8 set. 2026.

PILLOW. Pillow Documentation. Disponível em: https://pillow.readthedocs.io/. Acesso em: 26 set. 2026.

RIES, E. A startup enxuta: como os empreendedores atuais utilizam a inovação contínua para criar empresas extremamente bem-sucedidas. São Paulo: Leya, 2012.

RUSSELL, B. C. et al. LabelMe: A Database and Web-Based Tool for Image Annotation. International Journal of Computer Vision, v. 77, n. 1-3, p. 157-173, 2008.

SOMMERVILLE, I. Engenharia de software. 9. ed. São Paulo: Pearson Prentice Hall, 2011.

VIRTANEN, P. et al. SciPy 1.0: fundamental algorithms for scientific computing in Python. Nature Methods, v. 17, p. 261-272, 2020.

Link do repositório: https://github.com/ggstv-dl/Analise-Matricial