

Curso: Análise e Desenvolvimento de sistemas

Disciplina: Inteligência Artificial

Processamento Digital de Imagens Aéreas e Análise Topográfica Matricial via Python e WebODM

1. Identificação da equipe

Grupo composto pelos integrantes: Gustavo Barros Martins, Hugo Alexandre Carvalho Coelho Coutinho, Jeferson Machado dos Santos e Maicon de Sousa Pontes.

2. Apresentação da equipe ou cliente atendido

O cliente atendido é um engenheiro autônomo que prefere não ser identificado em um primeiro momento.

3. Descrição do problema identificado

Um dos grandes problemas enfrentados pelo profissional é o grande investimento de tempo em algumas atividades que poderiam facilmente ter o seu processo automatizado, como elas:

Necessidade constante de responder dúvidas superficiais de novos clientes e agendar visitas (interrompendo o trabalho técnico e gerando um atraso no processo atual).

Mapeamento manual de terrenos e análise de dados de elevação também consomem bastante o tempo do engenheiro, além de estarem sujeitos a erros humanos de interpretação.

4. Justificativa da solução proposta

Para uma solução do problema enfrentado com atendimento dos clientes e possíveis clientes, será implementado, no sistema que o grupo está desenvolvendo, um agente virtual baseado em LLMs para realizar uma triagem inicial. Capturar as necessidades dos clientes e extrair informações cruciais como (metragem, localização e tipo de obra). Já para processo de mapeamento e processamento de dados topográficos, algoritmos podem processar matrizes de dados de telemetria coletadas por drones para gerar modelos digitais do terreno. A IA pode ser programada para varrer automaticamente essas matrizes de altitude, identificando padrões, zonas de risco de alagamento ou os pontos mais seguros e nivelados para fundações e pousos, reduzindo o tempo de análise de dias para minutos.

5. Pesquisa e fundamentação do problema

Embora o uso de drones tenha agilizado as coletas em campo, o processamento do volume massivo das matrizes de elevação tornou-se um novo gargalo, visto que analisar



milhares de coordenadas manualmente para encontrar áreas planas é exaustivo e frequentemente trava os softwares CAD tradicionais. Para superar essa barreira e extrair inteligência dos dados em tempo hábil, a automatização do processo através de scripts baseados em vetores e matrizes apresenta-se como a solução ideal. Essa abordagem elimina falhas de interpretação visual e reduz o tempo de análise de dias para minutos, permitindo a entrega de mapeamentos e projetos estruturais mais eficientes e amparados em rigorosas avaliações matemáticas.

6. Lean Canvas

Problema	Solução	Proposta de valor única	Vantagem Injusta	Segmentos de clientes
Desperdício e dispêndio de grandes custos e tempo para mapear e topografar com dados obtidos no mapeamento de áreas por varredura de drones. O processo realizado manualmente é sujeito a erros humanos.	Automatizar o processo de análise de dados obtidos no mapeamento de áreas por varredura de drones. Métricas chave • Tempo médio de levantamento e precisão dos levantamentos. • Quantidade de levantamentos em determinado período. • Tempo para processar dados.	Diminuir o tempo de processamento e análise de dados para engenheiros que fazem esse trabalho de forma manual.	Em construção de uma comunidade com diversas parcerias com empresas de topografia. Canais - Perfil personalizado no Instagram e Facebook; - Campanhas diretas de engajamento; - Comparecimento em congressos e feiras de engenharia; - Atendimento via WhatsApp e Sites.	• Empresas de Engenharia Civil e Topografia. • Engenheiros e topógrafos focados no modelo B2B. • Engenheiros civis.
Estrutura de custos Desenvolvimento da plataforma, manutenção, produção de conteúdo, tráfego e hospedagem em servidores, além de custos com contratação de profissionais.		Fluxos de receita Planos de assinaturas mensais ou anuais, oferecidos nos formatos individual ou empresarial.		

7. Funcionalidades Essenciais

Ingestão e Tratamento de Dados Brutos: Módulo responsável pelo recebimento, leitura e parsing de arquivos de telemetria e imagens georreferenciadas. O componente realiza a conversão dos dados de altitude em matrizes numéricas manipuláveis para processamento matemático posterior.

Motor de Análise Matricial (Core): Algoritmo de varredura espacial projetado para subdividir o terreno em recortes matriciais (ex.: matrizes 4x4) e calcular os gradientes de inclinação. Esta rotina identifica automaticamente as coordenadas geográficas correspondentes a declives nulos ou próximos de zero (superfícies planas).

Módulo de Anotação e Filtragem: Funcionalidade voltada ao carregamento de máscaras de segmentação e delimitadores (bounding boxes), permitindo a exclusão automatizada de elementos indesejados (como vegetação, corpos d'água e edificações) da análise topográfica.



Exportação e Integração CAD: Sistema de geração de mapas de calor simplificados em formato de imagem e exportação dos polígonos representativos das zonas ideais para fundação em formatos vetoriais padronizados e compatíveis com softwares CAD (como .dxf).

8. Hipótese de Validação e Metodologia de Teste

8.1. Formulação da Hipótese

"A automatização da exportação de polígonos de fundação, por meio de algoritmos de análise de gradiente, reduzirá em no mínimo 50% o tempo dispendido por engenheiros civis e topógrafos no mapeamento de áreas seguras em comparação ao método de análise visual manual, mantendo o nível de precisão técnica exigido pelas normas da engenharia."

8.2. Procedimento de Teste

A validação será conduzida mediante a submissão de conjuntos de dados de telemetria oriundos de voos de drone em um terreno previamente documentado. Os resultados (outputs) gerados pelo script serão entregues a um engenheiro especialista para a realização de um estudo comparativo cego, avaliando a concordância espacial entre os polígonos gerados automaticamente e as áreas demarcadas manualmente pelo profissional.

9. Arquitetura Tecnológica e Ferramentas (Stack e IA)

A arquitetura do sistema foi desenvolvida priorizando o processamento local, a modularidade e o controle estrito sobre o fluxo de dados.

9.1. Ambiente e Infraestrutura de Desenvolvimento

Sistema Operacional: Ambiente Linux (distribuição Ubuntu), selecionado visando à máxima compatibilidade com bibliotecas open-source de fotogrametria, estabilidade de execução e eficiência na gestão de dependências.

Linguagem de Programação: Python, estruturado em scripts modulares projetados para execução via linha de comando no terminal.

Isolamento de Ambiente: Utilização de ambientes virtuais (venv) para a gestão individualizada de dependências, evitando conflitos entre o motor de cálculo numérico e as ferramentas de visão computacional.



9.2. Processamento Matemático e Algorítmico

NumPy e SciPy: Bibliotecas empregadas para a execução de operações algébricas de alto desempenho e fatiamento matricial (slicing) sobre os dados de altitude. Permitem a identificação rigorosa dos gradientes de inclinação sem demandar consumo excessivo de recursos computacionais.

9.3. Visão Computacional e Inteligência Artificial

A camada de Inteligência Artificial atua na classificação do terreno e no pré-processamento das imagens:

LabelMe: Ferramenta executada em ambiente virtual dedicado para a criação e estruturação do dataset. É utilizada no processo de anotação manual de ortomosaicos (definição de polígonos), rotulando obstáculos e vegetações a serem suprimidas.

OpenCV: Biblioteca responsável pelas rotinas de pré-processamento, filtragem e normalização das imagens aéreas obtidas pelo drone, antecedendo as etapas de análise matricial ou de treinamento de modelos.

Modelos de Segmentação Semântica: Implementação de arquiteturas de redes neurais convolucionais leves (como U-Net ou YOLO adaptadas para segmentação de instâncias). O modelo será treinado com o conjunto de anotações exportado do LabelMe, viabilizando a classificação automatizada e o isolamento do "solo nu" em relação aos elementos adjacentes do terreno.

10. Cronograma simplificado

Atividade	Ago	Set	Out	Nov
Infraestrutura	X			
Motor Matemático	X	X		
Visão e Anotação		X	X	
Exportação			X	
Validação			X	X
Deploy & Entrega				X



TED de Big Data e Ciência de Dados

1. Contextualização e problema do projeto

O projeto GeoMap teve sua proposta inicial desenvolvida no âmbito da disciplina de Inteligência Artificial, tendo como contexto a necessidade de auxiliar um engenheiro autônomo na análise de terrenos a partir de imagens aéreas obtidas por drones.

Entre os problemas identificados estava o tempo necessário para realizar manualmente a interpretação dessas imagens e identificar diferentes elementos presentes no terreno. A análise pode envolver a identificação de solo, vegetação, pedras, áreas pavimentadas, construções e outros elementos, podendo se tornar trabalhosa quando existe um grande volume de imagens.

A proposta inicial contemplava o processamento de informações topográficas, como matrizes de elevação e análise das características do terreno.

Para dar continuidade ao projeto, entretanto, foi realizada uma discussão sobre a proposta e seu desenvolvimento futuro. A partir dessa orientação, houve um novo direcionamento do escopo, passando a priorizar inicialmente a utilização de Inteligência Artificial para a segmentação semântica de imagens aéreas.

Assim, o presente TED de Big Data não representa um novo projeto, mas uma continuidade do trabalho desenvolvido anteriormente, aprofundando a etapa relacionada aos dados necessários para viabilizar essa nova direção.

2. Novo direcionamento e solução/MVP

A partir do direcionamento definido após a apresentação do projeto inicial, o foco principal passou a ser o desenvolvimento de uma solução capaz de realizar a segmentação semântica de imagens aéreas obtidas por drones.

A proposta consiste em utilizar técnicas de processamento digital de imagens e Inteligência Artificial para identificar diferentes regiões presentes em uma imagem e classificá-las de acordo com suas características.

Dessa forma, uma imagem aérea poderá ser utilizada como entrada do sistema, sendo posteriormente processada por um modelo capaz de identificar diferentes elementos presentes na cena.

Entre os elementos de interesse estão:



- Solo;
- Vegetação;
- Grama;
- Pedras;
- Cascalho;
- Árvores;
- Áreas pavimentadas;
- Construções;
- Muros;
- Cercas;
- Outros elementos presentes no terreno.

O foco inicial do MVP será, portanto, a segmentação das imagens e identificação dos elementos presentes nelas.

A análise topográfica, o processamento de matrizes de elevação, medições do terreno e possíveis integrações com ferramentas CAD permanecem como funcionalidades de expansão para etapas posteriores do projeto, caso sejam viáveis durante o desenvolvimento.

3. Necessidades de dados da solução

A mudança de direcionamento também altera as necessidades de dados do projeto. Para desenvolver uma solução capaz de realizar segmentação semântica, não são suficientes apenas imagens aéreas comuns.

É necessário possuir imagens acompanhadas de informações que indiquem quais regiões ou pixels pertencem a determinadas classes. Essas informações permitem que o modelo aprenda a relacionar os elementos presentes nas imagens com suas respectivas categorias.

Dessa forma, o conjunto de dados ideal para o projeto deve apresentar:

- Imagens aéreas obtidas por drones;
- Imagens com qualidade e resolução suficientes para identificar os elementos presentes no terreno;
- Diferentes ambientes e situações;
- Classes relacionadas aos elementos de interesse;
- Anotações ou máscaras de segmentação em nível de pixel;
- Quantidade suficiente de imagens para treinamento e avaliação;
- Dados adequados para técnicas de processamento digital de imagens e aprendizado de máquina.



Além das imagens e das respectivas anotações, também são relevantes características como resolução, formato dos arquivos, quantidade de registros, volume total dos dados e condições de utilização.

Essa necessidade de dados é justamente o ponto de ligação entre a solução proposta e a etapa de Big Data e Ciência de Dados desenvolvida neste trabalho.

4. Seleção do conjunto de dados

A partir das necessidades identificadas, foi realizada a busca por conjuntos de dados públicos que apresentassem características compatíveis com o novo direcionamento do projeto.

Entre as possibilidades encontradas, foi selecionado o Semantic Drone Dataset, desenvolvido pela Graz University of Technology (TU Graz).

A escolha está relacionada principalmente ao fato de o conjunto possuir imagens aéreas obtidas por drones acompanhadas de informações de segmentação semântica, permitindo que diferentes regiões das imagens sejam associadas a classes específicas.

Dessa forma, o dataset apresenta características diretamente relacionadas à necessidade identificada para o desenvolvimento futuro do MVP.

5. Fonte e origem dos dados

O Semantic Drone Dataset foi desenvolvido pela Graz University of Technology (TU Graz) para pesquisas relacionadas à compreensão semântica de cenas obtidas por drones.

A fonte oficial do conjunto de dados é:

Semantic Drone Dataset — Graz University of Technology

<https://ivc.tugraz.at/research-project/semantic-drone-dataset/>

O conjunto também está disponível em uma versão distribuída pelo Kaggle:

<https://www.kaggle.com/datasets/awsaf49/semantic-drone-dataset>

Para fins de referência e documentação do projeto, a página oficial da TU Graz será considerada a principal fonte.

6. Caracterização do conjunto de dados



O Semantic Drone Dataset é composto por imagens aéreas de alta resolução obtidas por drones, destinadas principalmente a tarefas de segmentação semântica.

As imagens foram capturadas aproximadamente entre 5 e 30 metros de altura e possuem resolução de aproximadamente 6000×4000 pixels.

A documentação oficial apresenta 400 imagens públicas de treinamento e 200 imagens privadas de teste, além de diferentes classes utilizadas para representar elementos presentes nas cenas.

Entre as categorias representadas encontram-se elementos como árvores, grama, vegetação, solo, cascalho, pedras, água, áreas pavimentadas, telhados, paredes, cercas e outros objetos.

Característica	Informação
Dataset	Semantic Drone Dataset
Instituição	Graz University of Technology (TU Graz)
Tipo de dado	Imagens aéreas
Origem	Imagens obtidas por drones
Resolução	6000×4000 pixels
Altura aproximada	5 a 30 metros
Imagens públicas de treinamento	400
Imagens privadas de teste	200
Classes semânticas	20
Anotação	Segmentação em nível de pixel

7. Principais atributos dos dados



Por se tratar de um conjunto de dados baseado em imagens, seus atributos não possuem a mesma estrutura encontrada em bases tabulares tradicionais.

Nesse caso, as principais informações relevantes para o projeto estão relacionadas às características das imagens e de suas anotações.

Atributo	Descrição
Imagem aérea	Imagem capturada por drone representando uma determinada cena
Resolução	Dimensão da imagem em pixels
Pixel	Unidade básica utilizada na representação da imagem
Classe semântica	Categoria atribuída a determinado elemento da cena
Máscara de segmentação	Informação que identifica a classe correspondente às regiões/pixels da imagem
Altura de captura	Altura aproximada em que a imagem foi obtida
Cena	Ambiente representado pela imagem

Essas informações são importantes porque o objetivo do modelo não será apenas reconhecer uma imagem inteira, mas identificar quais regiões pertencem a cada classe.

8. Quantidade e volume dos dados

O conjunto possui 400 imagens públicas destinadas ao treinamento e 200 imagens privadas destinadas ao teste, conforme as informações disponibilizadas pela fonte oficial.

Além da quantidade de imagens, o volume de dados também deve ser considerado. A versão disponibilizada no Kaggle possui aproximadamente 4 GB, o que representa um volume significativo para um projeto acadêmico que posteriormente deverá realizar processamento e treinamento de modelos.

A resolução de 6000×4000 pixels também contribui para o elevado volume computacional das imagens.



Por esse motivo, o tamanho dos dados será considerado durante as etapas futuras de preparação e processamento.

9. Formato e preparação dos dados

O dataset é composto por imagens e informações de anotação utilizadas na segmentação semântica.

Como as imagens possuem alta resolução, poderá ser necessário realizar etapas de pré-processamento antes da utilização no treinamento do modelo.

Entre as possibilidades estão:

- Organização das imagens e respectivas máscaras;
- Padronização dos dados;
- Redução da resolução das imagens, caso necessário;
- Divisão entre treinamento, validação e teste;
- Adequação dos dados ao modelo utilizado;
- Aplicação de técnicas de aumento de dados, caso sejam necessárias.

A redução da resolução será considerada apenas como uma etapa de preparação, caso os testes indiquem que o tamanho original das imagens apresenta um custo computacional elevado.

O dataset original será preservado, enquanto versões processadas poderão ser utilizadas para o desenvolvimento do modelo.

10. Justificativa da escolha

A escolha do Semantic Drone Dataset está diretamente relacionada às necessidades identificadas para o novo direcionamento do projeto.

O GeoMap necessita de imagens aéreas obtidas por drones e de informações que permitam identificar diferentes elementos presentes nessas imagens. O dataset selecionado apresenta justamente imagens aéreas acompanhadas de informações de segmentação semântica.

Além disso, a presença de classes relacionadas ao solo, vegetação, pedras, áreas pavimentadas e estruturas permite trabalhar com diferentes elementos que possuem relação com a análise de terrenos proposta pelo projeto.



Outro fator relevante é a existência de uma quantidade significativa de imagens e a disponibilização pública do conjunto para utilização acadêmica e de pesquisa, respeitando suas respectivas condições de uso.

11. Relação entre os dados e o problema

Os dados selecionados representam a base necessária para transformar a proposta de automatização da análise de imagens em uma solução baseada em Inteligência Artificial.

O processo planejado pode ser representado da seguinte forma:

Problema identificado



Análise manual de imagens aéreas



Necessidade de automatização



Imagens aéreas + máscaras de segmentação



Preparação dos dados



Treinamento do modelo



Segmentação semântica



Identificação dos elementos



Auxílio à análise do terreno



Assim, as imagens não serão utilizadas apenas como exemplos visuais, mas como dados de treinamento e avaliação para que o modelo possa aprender a diferenciar os elementos presentes nas cenas.

12. Limitações e desafios iniciais

O conjunto de dados apresenta algumas características que deverão ser consideradas durante o desenvolvimento.

A primeira delas está relacionada à alta resolução das imagens, que resulta em maior necessidade de memória, armazenamento e capacidade de processamento.

O volume de aproximadamente 4 GB da versão disponibilizada no Kaggle também representa um desafio para o processamento em equipamentos com recursos computacionais limitados.

Por esse motivo, poderá ser necessário realizar etapas de pré-processamento, incluindo a redução da resolução das imagens ou utilização de subconjuntos dos dados, sem alterar os arquivos originais.

Outra limitação está relacionada à diferença entre as características das imagens disponíveis no dataset e as imagens que poderão ser obtidas futuramente em situações reais. Diferenças de ambiente, iluminação, altitude, equipamentos e condições de captura podem influenciar o desempenho do modelo.

Também deverão ser observadas as condições de uso e distribuição estabelecidas pelos responsáveis pelo dataset. Por esse motivo, o conjunto original não será armazenado diretamente no repositório GitHub.

13. Considerações finais

O presente trabalho dá continuidade ao projeto inicialmente desenvolvido na disciplina de Inteligência Artificial, mantendo o problema e o contexto original, mas incorporando o novo direcionamento definido para as etapas seguintes do projeto.

A priorização da segmentação semântica de imagens aéreas estabelece uma necessidade específica de dados, levando à seleção do Semantic Drone Dataset como base para as futuras etapas de desenvolvimento.

A análise realizada neste trabalho permite compreender quais dados serão necessários, suas características, limitações e sua relação com o problema proposto.



Com essa etapa concluída, o projeto passa a possuir uma base de dados definida para as próximas fases, nas quais poderão ser realizadas a preparação das imagens, o desenvolvimento do modelo de segmentação e a avaliação dos resultados.



Referências

BRADSKI, G.; KAEHLER, A. **Learning OpenCV**: Computer Vision with the OpenCV Library. Sebastopol: O'Reilly Media, 2008.

GONZALEZ, R. C.; WOODS, R. E. **Processamento digital de imagens**. 3. ed. São Paulo: Pearson Prentice Hall, 2010.

HARRIS, C. R. *et al.* Array programming with NumPy. **Nature**, v. 585, n. 7825, p. 357-362, 2020.

LILLESAND, T.; KIEFER, R. W.; CHIPMAN, J. **Remote sensing and image interpretation**. 7. ed. Hoboken: John Wiley & Sons, 2015.

OPENDRONEMAP. **WebODM Documentation**. Disponível em: <https://docs.opendronemap.org>. Acesso em: 8 set. 2026.

RIES, E. **A startup enxuta**: como os empreendedores atuais utilizam a inovação contínua para criar empresas extremamente bem-sucedidas. São Paulo: Leya, 2012.

RUSSELL, B. C. *et al.* LabelMe: A Database and Web-Based Tool for Image Annotation. **International Journal of Computer Vision**, v. 77, n. 1-3, p. 157-173, 2008.

SOMMERVILLE, I. **Engenharia de software**. 9. ed. São Paulo: Pearson Prentice Hall, 2011.

VIRTANEN, P. *et al.* SciPy 1.0: fundamental algorithms for scientific computing in Python. **Nature Methods**, v. 17, p. 261-272, 2020.

Link do repositório: <https://github.com/ggstv-dl/Analise-Matricial>

